

# Vigilancia y diagnóstico de sistemas complejos

Por: Henry Sarmiento M.

Docente Ing. en Instrumentación y Control.

PCJIC

## 1. Introducción

A nivel industrial, los fallos o defectos que puedan presentarse (subprocesos, equipos o dispositivos) en los procesos, y que no son corregidos a tiempo, son la causa de una gran cantidad de daños, disminución de la producción, pérdidas económicas y ambientales, y accidentes que pueden involucrar pérdida de vidas. La detección y diagnóstico de fallos en los procesos industriales son una ayuda para evitar estados de colapso de los sistemas brindando seguridad, disponibilidad y confiabilidad en un proceso industrial.

La automatización de procesos industriales que inicialmente se enfocaba en obtener el máximo incremento en la producción y la reducción de costos, hoy da relevante importancia a la seguridad de la operación. Víctimas humanas o daños al medio ambiente como consecuencia de accidentes industriales no son aceptables en nuestra sociedad actual (Gentil et al., 2007).

En el concepto global de la automatización de procesos se incluye la tarea de prevención de accidentes. Esta tarea de prevención puede ser realizada por medio de la supervisión orientada a evitar caer en estados (o situaciones) peligrosos del proceso. Detectar tempranamente estos modos de funcionamiento anormal permite al operador ejecutar acciones que retornen el proceso a estados de normal operación, y por esta razón ayudas son de gran interés para la industria.

El diagnóstico automático es parte esencial en los sistemas de producción (Duda et al., 2001).

La automatización, además del control y la optimización de variables, tiene como objetivo garantizar la seguridad. Seguridad conseguida a través la vigilancia, diagnóstico en línea y mantenimiento preventivo. Estas tareas son parte de la supervisión de una planta industrial.

Hoy en día la mayoría de los procesos industriales se caracterizan por ser procesos complejos debido, entre otros factores, a la gran cantidad de variables que intervienen en el proceso y a su no linealidad. La no linealidad conlleva al problema de la complejidad de estos sistemas y aumenta la dificultad de encontrar un modelo exacto o útil para la supervisión. Por otro lado, el gran número de variables disponibles que se deben analizar implica la denominada 'maldición de la dimensionalidad' (*curse of dimensionality*), que plantea que el número de datos que hace falta para hacer estimaciones suficientemente precisas, a partir de los mismos, aumenta exponencialmente con la dimensión del espacio

de datos (Bellman, 1967). También la incertidumbre y la imprevisibilidad en los procesos hacen más difícil la tarea de toma de decisiones.

En los procesos complejos la tarea de prevención y planificación es difícil, y requiere tomar decisiones con gran cantidad de incertidumbre en las variables, motivo por el cual los operadores humanos siguen estando a cargo de grades instalaciones industriales. El operador humano tiene la importante cualidad de saber manejar lo inesperado o incierto y de realizar las acciones requeridas para evitar funcionamientos anormales en el proceso. Sin embargo, tiene una capacidad limitada, en relación con los sistemas automáticos, de analizar simultáneamente un gran número de variables.

Por tanto, en los sistemas complejos, los sistemas de vigilancia y diagnóstico automático deben ser capaces de trabajar ante altos niveles de incertidumbre e incluir el conocimiento o experiencia humana (Gentil et al., 2007), convirtiéndose en herramienta de apoyo en la toma de decisiones del operario humano. Con la dificultad de obtener modelos para estos procesos, el conocimiento acerca del sistema puede ser obtenido a partir de medidas registradas durante situaciones normales y anormales (técnicas de aprendizaje basadas en datos), y de mecanismos de aprendizaje basados en datos. Este conocimiento puede ser organizado como una partición de los datos históricos en clases que representan los estados funcionales del proceso (situaciones del proceso) y son definidas a partir de los datos históricos registrados.

Los métodos de aprendizaje basados en datos permiten extraer información que caracteriza los estados normales o anormales (de falla) del sistema e identificar las clases de funcionamiento que puede presentar el proceso. La utilización de técnicas de inteligencia artificial y lógica difusa para el diagnóstico de sistemas complejos permite obtener resultados que son interpretables y ofrecer una información útil para la toma de decisiones necesaria en caso de fallas (Aguilar-Martin, 2007).

En resumen, los sistemas de supervisión requieren de la articulación entre las habilidades humanas y las fortalezas, ventajas y potencialidades de las máquinas con el objetivo de mejorar la efectividad en la tarea de toma de decisiones. Entonces, se considera importante y necesario mejorar o proponer nuevas técnicas en la automatización y la interpretación de resultados. En este sentido, en esta tesis se propone un método que pretende ser una ayuda útil para los operadores de procesos en la tarea de identificar y predecir claramente los estados funcionales del sistema mediante técnicas basadas en el análisis de datos.

A continuación se presentan los conceptos generales de la supervisión y los sistemas de monitoreo automático, y el objetivo principal es el de contextualizar el uso de métodos de clasificación en el monitoreo, que son también útiles en el diagnóstico de los sistemas complejos.

## 2. Definición de sistemas complejos

La definición de sistemas complejos relaciona tanto las características propias del proceso en estudio como las consecuencias que estas ocasionan para el diseño y puesta en funcionamiento de la automatización requerida (gestión, supervisión y control).

Con respecto a las características del proceso, su complejidad se asocia al hecho de que los procesos industriales proveen una gran cantidad de variables que normalmente son de tipo no lineal y tienen alta correlación. Esta característica de no linealidad es un problema

importante ya que en la teoría de control de sistemas, los desarrollos y herramientas disponibles han sido históricamente profusos para sistemas lineales; y un modelo de ecuaciones explícitas -suficientemente preciso- de un proceso no lineal, si es posible de obtener, es difícil o casi imposible de manipular. También, la complejidad del sistema se ve influenciada por el gran número de variables que interactúan.

Por otro lado, en Gentil et al. (2007) se plantea que los procesos complejos están inmersos en ambientes abiertos donde la incertidumbre, la imprevisibilidad y la dinámica de los fenómenos asociados hacen de la toma de decisiones una tarea difícil. También adiciona que en estos procesos están presentes diversos modos de funcionamiento (llamados estados funcionales) incluyendo los estados de falla, y que a su vez puede presentarse un variado número de modos que se puede asociar a estados de funcionamiento normal.

Como consecuencia del problema de la no linealidad y la dificultad derivada de no poder obtener y manipular modelos explícitos, se hace necesario trabajar con modelos basados en datos. Respecto al problema de la dimensionalidad, se requiere abordar el uso de técnicas que permitan reducir la dimensionalidad para descartar o eliminar componentes de los vectores de datos (variables) que no contengan información significativa o que contengan información redundante (Cuadrado, 2002).

En los sistemas complejos los modos de falla son difíciles de predecir, y si se presentan pueden causar el paro total o la necesidad de un cambio en las consignas de los controladores para trabajar en condiciones de funcionamiento degradadas; y en algunas ocasiones es necesario hacer un cambio total de los esquemas de control. Por lo anterior, para estos sistemas resulta particularmente necesario detectar tendencias que puedan dar información de que el sistema va hacia estados anormales y entonces tomar acciones que lo eviten.

Dado que el conocimiento de la dinámica del proceso es importante para interpretar correctamente las situaciones, y que estos procesos tienen dinámicas muy complejas, la localización y aislamiento de fallos es especialmente difícil usando técnicas clásicas. Toman entonces especial relevancia las técnicas de inteligencia artificial donde el modelo del sistema puede ser extraído de los datos históricos del proceso, y el conocimiento del experto, la reducción de dimensionalidad y el manejo de la incertidumbre pueden ser incluidos.

### 3. La vigilancia y el diagnóstico en la supervisión de procesos

La supervisión de un proceso puede ser definida como la acción de vigilar un sistema, con el objetivo de decidir y realizar las acciones necesarias si este se aleja del objetivo programado. La vigilancia relaciona la tarea de detectar el comportamiento del sistema identificando el estado funcional actual y a su vez diferenciarlo de otros posibles estados (normales o defectuosos) del proceso. El diagnóstico es definido como la identificación de la naturaleza de un mal funcionamiento o falla en el proceso.

Se considera también el diagnóstico como la identificación de las causas de los diversos modos del proceso, incluye no sólo los modos de funcionamiento normal sino también los modos de fallo, que corresponden a diferentes estados que puede tomar un proceso

cuando es afectado por un fallo o condiciones de funcionamiento incorrectas y que son difíciles de prever (Gentil et al., 2007).

Con relación a la supervisión, vigilancia y diagnóstico de procesos, es necesario definir conceptos básicos relacionados. En general, en la literatura, la terminología en este campo no es consistente, dado que en algunas definiciones no hay consenso general en los alcances relacionados. Gentil et al. (2007) relaciona conceptos tales como:

- *Funcionamiento normal de un sistema.* Estado de funcionamiento normal donde las variables lo caracterizan permanecen en (o muy próximas a) sus valores nominales. El sistema se dice defectuoso en caso contrario.
- *Falla.* Es la causa de una anomalía.
- *Degradación.* Es lo que caracteriza el procedimiento que conduce un proceso a un estado defectuoso.
- *Defecto.* Se define como un comportamiento anormal de un sistema sin necesariamente cuestionar su función.
- *Avería.* Es lo que caracteriza la incapacidad de un dispositivo para cumplir una función específica. Se refieren por lo general a los componentes mariales de un proceso que han dejado de funcionar, por ejemplo los sensores.
- *Síntoma.* Un síntoma es el evento o conjunto de datos a través de los cuales el sistema de detección identifica el paso del proceso a un funcionamiento anormal. Este es el único elemento que se conoce el sistema de vigilancia en el momento de la detección de una anomalía.

El defecto es constatado gracias a un indicador de defectos que revela la presencia de una falla. El indicador de defecto en la práctica es elaborado por medio de las variables medidas en la instalación o proceso (Gentil et al., 2007). Este indicador permite detectar el estado presente del sistema y en el caso de falla estimar las causas del problema.

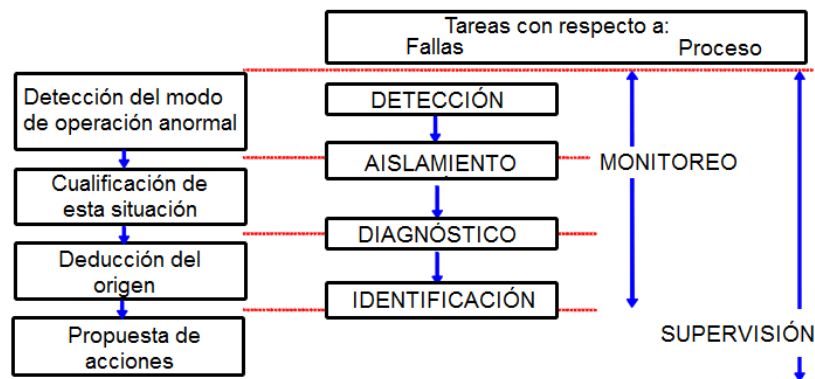
Iserman y Balle (1997) define los conceptos de acuerdo a:

- El estado y sus señales:
  - *Fallo (fault)* es una desviación no permitida de al menos una propiedad característica o variable del sistema respecto al comportamiento considerado aceptable/ usual/ estándar/ nominal.
  - *Fallo total (failure)* es un fallo que implica una interrupción permanente de la capacidad del sistema para llevar a cabo una función requerida bajo condiciones de funcionamiento especificadas.
  - *Mal funcionamiento (malfunction)* es la irregularidad en el cumplimiento de una función deseada del sistema.
  - *Error (error)* es una desviación entre una medida o valor calculado de una variable de salida y su valor especificado o teóricamente correcto.
  - *Disturbio (disturbance)* es una entrada desconocida y no controlada actuando sobre el sistema.
  - *Perturbación (perturbation)* es una entrada actuando sobre el sistema y que ocasiona un desviación temporal del estado estable.
  - *Síntoma (Symptom):* Un cambio de una cantidad observable con respecto a su comportamiento normal.

- Las funciones, que hacen parte de un sistema de supervisión:
  - *Detección de Fallos (fault detection)* es determinar si hay fallos presentes en el sistema y el tiempo de detección.
  - *Aislamiento de fallo (fault isolation)* es la determinación del tipo, localización y tiempo de detección del fallo; la determinación de cual componente ha fallado. Sigue a la detección de fallo.
  - *Identificación de fallo (fault identification)* es la determinación de la cuantía y el comportamiento a lo largo del tiempo de fallo. Se realiza después del aislamiento de fallo.
  - *Diagnóstico de fallo (fault diagnosis)* es determinar el tipo, cuantía, localización y tiempo de detección de un fallo. Sigue a la detección de fallo e incluye aislamiento e identificación. En otras definiciones solo incluye detección y aislamiento de fallo.
  - *Monitoreo (monitoring)* es una tarea en tiempo real para determinar las condiciones de un sistema físico registrando información, y reconociendo e indicando anomalías en su comportamiento.
  - *Supervisión (supervision)* incluye el monitoreo y diagnóstico de un sistema físico y la ejecución de las acciones apropiadas para mantener el funcionamiento en caso de fallo.
  - *Protección (protection)*: Medio por el cual se suprime un comportamiento potencialmente peligroso del sistema si es posible o, los medios por los cuales las consecuencias de un comportamiento peligroso se evitan.
- Los modelos, para la representación del proceso:
  - *Modelo cuantitativo (quantitative model)* es el uso de las relaciones dinámicas y estáticas entre variables de un sistema y los parámetros del mismo en orden a describir el comportamiento de un sistema en términos matemáticos cuantitativos (también llamados modelos numéricos o analíticos).
  - *Modelo cualitativo (qualitative model)* es el uso de las relaciones dinámicas y estáticas entre variables de un sistema y los parámetros del mismo en orden a describir el comportamiento del sistema en términos cualitativos como las causalidades de las reglas *if-then*.
  - *Modelo de Diagnóstico (diagnostic model)* es un grupo de relaciones dinámicas y estáticas las cuales relacionan variables de entrada específicas -los síntomas- a variables de salida específicas -los fallos-.
- Las propiedades del sistema y sus medidas:
  - *Confiabilidad (reliability)*. Capacidad de un sistema para realizar una función requerida bajo condiciones establecidas, dentro de un panorama dado, durante un período de tiempo dado. Esta puede ser medida calculando el valor medio de tiempo transcurrido entre dos fallas consecutivas.
  - *Seguridad (safety)*: Capacidad de un sistema de para no causar daño a las personas, equipos o el ambiente.

Todos los elementos anteriores corresponden a las diferentes etapas en el estudio de fallos en plantas o procesos, donde la mayor parte de los trabajos relacionados están centrados en: detección de fallas, diagnóstico de fallas, monitoreo (vigilancia) y supervisión. En la concepción de la supervisión, además de las tareas relacionadas con las fallas -como se observa en la Fig. 1.1-, se incluye la propuesta de las acciones

requeridas en el proceso. La detección, el aislamiento y la identificación de fallos son tareas del problema de la supervisión, ya que no incluye la actuación sobre el sistema estudiado para llevarlo al funcionamiento que se considera correcto. Sin embargo, si se puede llegar hasta la identificación del fallo, la acción correctora que debe realizar el operador puede ser deducida, a partir de los indicadores que se generan al detectar un fallo.



**Fig. 0.1 Supervisión y tareas relacionadas**

Debido a la importancia de los objetivos de la supervisión de procesos, métodos avanzados para el monitoreo o vigilancia y diagnóstico de fallos son necesarios para responder a exigencias tales como: anticipación a la detección de fallos, el diagnóstico de daño en sensores y accionamientos, las fallas en el comportamiento del proceso, la detección de fallos en los bucles cerrados y la supervisión del proceso durante estados transitorios. El objetivo de la anticipación en la detección y diagnóstico de fallos es disponer de tiempo suficiente para hacer frente a acciones como la reconfiguración o mantenimiento del proceso.

La tendencia en monitoreo y vigilancia de sistemas complejos es tener en cuenta la información proveniente de las diferentes variables que pueden ser registradas en el proceso y las relaciones que estas guardan entre sí. La supervisión clásica basada en una(s) variable(s) determinada(s) puede conducir a resultados incorrectos en muchos casos (Akbaryan y Bishnoi, 2001).

Un sistema avanzado de vigilancia debe incluir ayudas para reducir la carga de trabajo y la frecuencia de errores humanos, sin eliminar al operador de la función de decisión. Pero hay una dificultad particular en las tareas relacionadas con la detección de condiciones anormales, la identificación de la situación y la predicción de su evolución, por lo cual es importante desarrollar y mejorar las herramientas para este trabajo de supervisión basado en la cooperación hombre / máquina en la que el hombre no sólo ve asistido en sus tareas rutinarias, sino también en sus tareas de razonamiento (Gentil et al., 2007).

Dada la dificultad de interpretar correctamente las alarmas existentes a partir del análisis de las variables individuales, las herramientas para vincular las fallas a diferentes variables son muy útiles para el diagnóstico y la supervisión.

Entonces, el nuevo trabajo se sitúa en el dominio de la identificación y predicción automática de estados (normales o de falla) con el objetivo de dar una ayuda al operador del proceso. Las tareas de identificación y predicción son incluidas en los sistemas de

vigilancia y diagnóstico en vía de efectuar un reconocimiento y predicción de estados en línea (Gentil et al., 2007).

Para mejorar la aplicación de los sistemas de monitoreo o vigilancia, es necesario potenciar técnicas que sean fácilmente utilizadas por los expertos de procesos. Hay una necesidad de técnicas que sean fáciles de interpretar en el contexto de un mismo proceso en el que el experto tiene un amplio conocimiento (Vázquez, 2007). Se pretende dar una ayuda al experto del proceso, que no es generalmente un experto en técnicas de monitoreo o vigilancia. Esta ayuda se basa en una caracterización y predicción adecuada de estados funcionales, cuando la identificación se realiza con métodos de clasificación difusa.

Evitar falsas alarmas es otro elemento que debe ser objetivo de aplicación de los métodos de diagnóstico, y que debe tenerse en cuenta en la construcción o mejoramiento de un sistema supervisión útil (Isaza et al., 2007).

#### 4. Técnicas empleadas para el diagnóstico automático

En el problema de la detección, aislamiento e identificación de fallos son muchas las herramientas usadas. En la literatura la clasificación de estas técnicas no es homogénea, sin embargo, la organización básica más general hace referencia a los métodos basados en modelos y los métodos basados en datos.

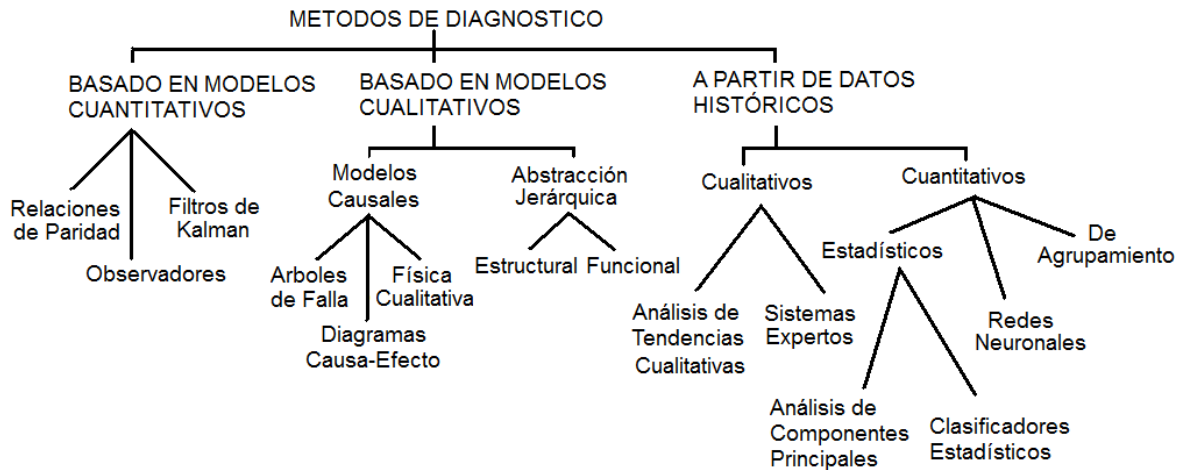
Entre las técnicas útiles para realizar la tarea de diagnóstico automático, se tienen en cuenta los métodos que identifican estados funcionales por medio de técnicas de clasificación o agrupamiento. Los prototipos de clases que los métodos de identificación de estados encuentran en una etapa de entrenamiento, son utilizados en el monitoreo en línea para establecer en cada muestreo el estado actual (estado normal, estado de alarma o estado de fallo). Detectar un estado de falla es uno de los pasos del diagnóstico y es el aporte de los métodos de identificación de estados en un sistema de diagnóstico de fallos. Adicionalmente, también es posible que los prototipos de clases que son obtenidos con base en la información de las variables registradas del proceso puedan dar indicios de la procedencia de la falla completando el diagnóstico.

En este trabajo se toma como referencia la clasificación de métodos de diagnóstico presentada en Isaza (2007), existen otras propuestas en la literatura (Cuadrado, 2002; Venkatasubramanian et al., 2003; Gamero, 2012). La propuesta de Isaza (2007) está basada en la clasificación presentada en Venkatasubramanian et al. (2003) donde se adicionan los métodos de agrupamiento al grupo de métodos cuantitativos entre los métodos de diagnóstico desarrollados a partir de datos históricos.

En Isaza (2007) la clasificación asocia los Métodos basados en Modelos (Modelos Cuantitativos y Modelos Cualitativos) y los Métodos basados en Datos Históricos como se puede observar en la Fig. 1.2.

Con relación a las técnicas utilizadas para el diagnóstico automático Isaza (2007) describe el problema de la vigilancia tradicional de variables individuales (donde se verifica que permanezcan dentro de un dominio o límites del funcionamiento normal) sin tener en cuenta las relaciones que guardan las variables entre sí (Kuorti, 2002) y justifica así la necesidad de análisis multivariable que podrían proveer las herramientas de inteligencia artificial. También describe que en la actualidad los automatismos realizan la tarea de

almacenamiento de muchas variables que incluyen el comportamiento en presencia de fallas, por lo que justifica la utilización de éstos datos para extraer el conocimiento.



**Fig. 0.2 Clasificación Métodos de Diagnostico Incluyendo Agrupamiento [Tomada de Isaza (2007)]**

En los métodos basados en datos históricos, los métodos de aprendizaje y de reconocimiento de patrones permitirán a partir de datos del proceso obtener información de los estados del sistema.

Los métodos basados en minería de datos hacen la identificación de fallos (estados funcionales del proceso) a partir del tratamiento de un gran número de muestras, y estos métodos tienen muchas propiedades útiles para el diagnóstico de procesos complejos, entre ellas:

- Trabajar de manera indiferente con procesos no lineales ya que no es necesario un modelo del proceso.
- Extraer la información de los datos de entrenamiento (noción de aprendizaje)(Koivo, 1994).
- El conocimiento es automáticamente extraído de los datos, donde las clases obtenidas corresponde a las situaciones de funcionamiento normal o de fallo del proceso.

Se señala como un gran inconveniente de estos métodos la dependencia de los datos de entrenamiento. Ellos necesitan tener datos de entrenamiento que permitan caracterizar cada estado. Sin embargo, algunas técnicas permiten también actualizar las clases (aprendizaje activo) basándose en datos reconocidos (por ejemplo LAMDA (Kempowsky, 2004)). También se menciona que, los comportamientos de estos métodos están fuertemente ligados a una buena selección de parámetros que son propios de cada algoritmo (Babuska, 1998; Casimir, 2003; Franco et al., 2002; Kaymak y Babuska, 1995; Lurette, 2003).

Otros de los aspectos generales mencionados en Isaza (2007) son:

- la diferenciación de las dos grandes fases que componen los métodos basados en datos: el entrenamiento o aprendizaje fuera de línea (establecimiento de las características de las clases y el reconocimiento de nuevos datos) y el reconocimiento en línea (donde se realiza la vigilancia y diagnóstico).



- la necesidad de un pre tratamiento de datos para establecer las variables más pertinentes que permitan detectar los estados del sistema, y eliminar ruidos que permitan obtener la mejor información posible de cada variable. El pre tratamiento incluye las operaciones clásicas utilizadas en la automática y el tratamiento de señales (filtraje, análisis frecuencial, entre otros) (Chiang et al., 2001).
- la extensión del histórico de datos debe seleccionarse en función de la dinámica del proceso teniendo en cuenta la reacción ante cambios de consigna y ante ciertas fallas; las fallas más difíciles de detectar son las que se presentan lentamente, ya que puede llevarse un largo tiempo para que aparezcan sus efectos (Gentil et al., 2007).

La propuesta de clasificación de métodos de diagnóstico propuesta por Isaza (2007) y otras propuestas, coinciden en destacar las técnicas de diagnóstico basadas en datos como un grupo de relevante importancia. Los diferentes autores hacen énfasis en el hecho de que los datos que pueden ser registrados durante el funcionamiento del proceso permiten obtener un conocimiento de este tal que es posible incluir este conocimiento en el diagnóstico de procesos industriales complejos. En la actualidad una gran cantidad de trabajos en la supervisión de procesos incluyen estas técnicas, dentro de las cuales son utilizados actualmente algoritmos de Inteligencia Artificial (IA). Los algoritmos de IA tienen importantes características que son requeridas para realizar la tarea de supervisión destacándose entre ellas la capacidad de análisis multivariable, reducción de dimensionalidad y la posibilidad de incluir e interactuar con el conocimiento propio de experto en el proceso (interacción hombre-máquina). Un hecho importante es la inclusión de estos métodos como soporte a la tarea de toma de decisiones en los procesos.

Finalmente, los clasificadores ubicados en el esquema de supervisión han sido de gran importancia y tienen acogida por la forma sencilla en que estos operan permitiendo una clara interacción entre el experto, la automatización y el proceso.

## 5. Diagnóstico aplicando métodos de clasificación difusos

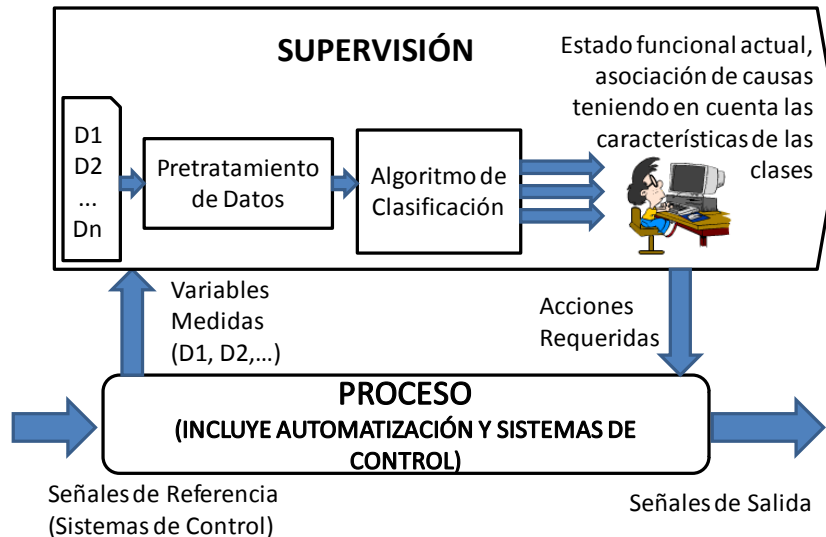
Los métodos de clasificación hacen parte de los métodos basados en minería de datos.

El principio de la vigilancia (monitoreo) de un proceso dinámico basado en clasificadores es el de determinar para cada muestra -tomada del proceso- la clase en la que es ubicada, y que previamente fue asociada a un estado funcional o situación del sistema según el criterio y conocimiento del experto. Un esquema que representa la supervisión de procesos con base en clasificadores es presentado en la Fig. 1.3.

Los métodos de clasificación tienen la característica de presentar la información disponible en forma compacta, es decir obtener grupos o clases que relacionan variables y representan los comportamientos típicos de un proceso (funcionamiento normal o anormal). Con estas características un operador puede tener en cada momento una visión sintetizada del proceso que le permita reaccionar mucho más rápido ante la ocurrencia de anomalías.

La efectividad de la acción que debe ejecutar el operador en el sistema depende, entre otros, de la capacidad que se tenga de determinar con éxito el origen o causa del mal funcionamiento (el diagnóstico). En el caso de técnicas de clasificación, los prototipos de clase por medio de los cuales son determinados los estados funcionales en línea, son la herramienta para encontrar la causa del problema. Los prototipos permiten evaluar la incidencia que tienen las variables en la clase (al cambiar de clase cambia el prototipo). Por consiguiente si existen variables que, al modificar sus valores son la causa de cambios de estado, son tomadas de puntos específicos sobre el proceso, entonces se

puede direccionar la búsqueda de la causa hacia los dispositivos, equipos o subprocesos que las contienen. Este análisis es aplicable una vez se ha identificado el estado del proceso, pero resultaría ser aún más útil si se hace con base en una predicción de estado funcional. La predicción es en sí, una herramienta poderosa tanto para el monitoreo como para el diagnóstico de procesos.



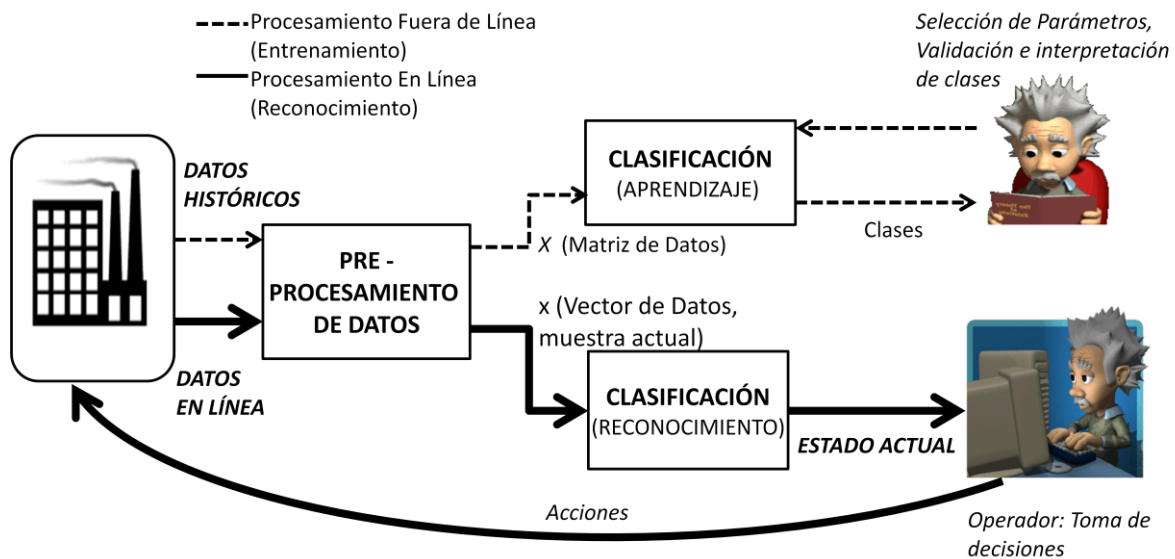
**Fig. 0.3 Esquema de supervisión con base en clasificadores**

Los métodos de clasificación (en especial los estadísticos) permiten obtener un modelo comportamental o de estados del sistema, donde son incluidos estados de falla. Las características estadísticas de una señal pueden ser consideradas como un modelo representativo de un comportamiento ya sea normal o de falla, y si se observan cambios o modificaciones en estas características se pueden interpretar como cambios en el comportamiento del proceso.

La utilización de técnicas de Inteligencia Artificial y la Lógica Difusa para el diagnóstico de sistemas permite obtener resultados fácilmente interpretables por el operador del proceso y ofrece una información útil para la toma de decisiones que debe ser realizada en caso de falla.

El diagnóstico utilizando métodos de clasificación tiene dos etapas principales: el entrenamiento (aprendizaje) y el reconocimiento.

*La etapa de entrenamiento o aprendizaje (fuera de línea)*, es la primera etapa y su objetivo es encontrar, a partir de los datos históricos, las características y prototipos del comportamiento del sistema que permiten diferenciar los estados funcionales en los que puede estar el sistema (Figura 1.4). En esta etapa la intervención del experto en el proceso es crucial. En esta fase, los datos se agrupan y discriminan para llegar a la construcción de las clases, y el resultado es un clasificador que se puede asociar a un modelo comportamental del sistema. El clasificador permite asociar a las diferentes clases, las nuevas observaciones que corresponden a los valores actuales de las variables y asociar las causas de los fallos cuando la clase corresponde a una condición de fallo. Con relación al aprendizaje, es un área de trabajo y mejoramiento continuo, y que depende fuertemente de cada aplicación (Dubuisson, 2001).



**Fig. 0.4 Esquema de diagnóstico utilizando técnicas de clasificación**

La propuesta que se presenta en este documento utiliza (en una primera etapa)- los resultados de clasificación de los datos de entrenamiento del clasificador difuso para entrenar un predictor de grados de pertenencia difusa. Dado que el predictor depende de la calidad del clasificador, es indispensable que este último tenga el mejor desempeño posible en cuanto a la correcta diferenciación de situaciones del proceso.

*El reconocimiento de situaciones se efectúa en línea*, es la segunda etapa, donde el reconocimiento de nuevos datos (muestras) es realizado para identificar el estado correspondiente. Los datos son clasificados en función del clasificador obtenido en la etapa de entrenamiento.

La propuesta que se realiza en este documento, en una segunda etapa, utiliza los resultados del reconocimiento en línea de cada muestra para ser procesados por el predictor de grados de pertenencia difusos. Con base en estos grados de pertenencia difusos es posible predecir estados en el proceso.

#### 5.1. Métodos de aprendizaje y de reconocimiento de patrones útiles para el diagnóstico

En López (2001) se asocian características generales de los métodos existentes con base en la descripción de los cuatro pasos relacionados con el aprendizaje y reconocimiento de patrones: Descripción del proceso, Análisis de Características, Análisis de agrupaciones y Diseño del clasificador.

Con el fin de identificar los estados de sistemas a partir de datos, muchos algoritmos han sido propuestos, cada uno de ellos tiene criterios diferentes para obtener la partición del espacio de datos.

Según Bezdek (1981) son definidos tres tipos principales de criterios de agrupamiento:

- *Métodos jerárquicos*, que tienen su origen en estudios de taxonomía. Los grupos se forman recalculando la pertenencia con cada muestra de la base de entrenamiento, en función de alguna medida de similitud. Dentro de estos métodos hay técnicas aglomerativas (el punto de partida son  $N$  conjuntos compuestos por 1 elemento, por lo que el funcionamiento del algoritmo es unir los grupos de forma iterativa) y técnicas divisivas (donde el punto de partida es un conjunto de  $N$  elementos, por lo que el algoritmo va dividiendo iterativamente el conjunto en otros más pequeños).

- *Métodos de grafos teóricos*, donde se supone que los datos son un conjunto de nodos, siendo los pesos entre pares de nodos alguna medida de similitud. El criterio de agrupamiento suele ser alguna medida de conectividad entre los nodos y frecuentemente la estrategia de agrupamiento es el cálculo del árbol de expansión mínimo. Estos métodos se suelen utilizar en datos con estructura pseudo-lineal.

- *Métodos de función objetivo*, permiten una formulación más precisa (aunque no necesariamente más válida) del criterio de agrupamiento. Una función objetivo mide la 'bondad' de las agrupaciones candidato, siendo los máximos o mínimos locales las agrupaciones óptimas. Un ejemplo de estos métodos es el uso como medida de la distancia euclídea y como función objetivo la suma cuadrática de la distancia entre los puntos y un 'prototipo' o valor medio del conjunto. Así pues, el objetivo del agrupamiento es minimizar dicho sumatoria.

Los diferentes métodos tienen dos aproximaciones que depende de la estructura de la partición: Agrupamiento estricto o concreto donde un objeto o muestra sólo puede pertenecer a un conjunto o clase (Hard clustering) y Agrupamiento borroso o difuso (Fuzzy clustering) donde los objetos o muestras pueden pertenecer a más de un conjunto con un grado de pertenencia a cada partición.

Formalmente, un grupo de  $n$  vectores de datos  $X=[x_1, x_2, \dots, x_n]$  con  $a$  atributos cada uno, donde  $n$  corresponde al número de muestras (tiempos de muestreo), es dividido (usando un método de agrupamiento) en  $m$  grupos o clases. El agrupamiento concreto permite obtener la matriz de pertenencias asignando el valor de 1 de acuerdo a la clase a la que corresponde la muestra y cero en las demás. El agrupamiento difuso permite obtener la matriz de grados de pertenencia  $U=[\mu_{jf}]_{m \times n}$ , donde  $\mu_{jf}$  representa el grado de pertenencia difusa de la muestra  $f$  al  $j$ -ésimo grupo. El máximo grado de pertenencia es 1 y el mínimo es 0. A partir del análisis de los grados de pertenencia difusa por cada muestra  $f$ , se puede determinar la clase en la que es ubicada la muestra. En general, el mayor grado de pertenencia determina la clase que es asignada a la muestra (ver (1.1)).

$$C_f=j, \text{ donde } j \text{ corresponde a la clase en la cual } \mu_{jf} \text{ es máximo } (\max(\mu_j)); j=1,2,\dots,m., \text{ para cada } f \quad (1.1)$$

Existe una gran cantidad de algoritmos de agrupamiento con función objetivo del tipo concreto, cada uno corresponde a una técnica de optimización diferente (algoritmos iterativos, mapas auto organizados, algoritmos evolutivos, entre otros), en este caso se menciona uno de los más representativos denominado ISODATA o Hard C means (Lopez, 2001).

En el algoritmo ISODATA la función a minimizar es la suma cuadrática de las distancias euclídeas de cada punto a los centroides de todos los conjuntos. En este algoritmo se han detectado problemas tales como: la necesidad de reglas para la solución de empates (un mismo punto puede tener igual distancia a dos centroides), puede encontrar mínimos

locales sin asegurar mínimos globales y las particiones tienen la forma regular de hiperesferas.

De acuerdo con Yan (1993) existen tres categorías de agrupamiento difuso: la basada en función objetivo, la basada en relaciones difusas y la generalización del algoritmo 'k-nearest neighbour'. Entre los algoritmos difusos basados en una función objetivo, el Fuzzy C-Means (FCM) (Bezdek, 1981) y el GK-Means (GKM) (Gustafson y Kessel, 1978) han sido ampliamente utilizados. Estos dos algoritmos utilizan un mismo criterio de optimización  $J_b$  (que hace posible agrupar los datos de acuerdo con la similitud entre ellos, ver ec. (1.2)), donde el valor del subíndice  $b$  regula la 'fusividad' de la partición.

$$J_b(U, v) = \sum_{i=1}^n \sum_{j=1}^m (\mu_{ij})^b (d_{ij})^2 \quad (1.2)$$

En estos algoritmos, la similitud es evaluada por medio de la función de distancia  $d_{ij}$  (1.3), del dato  $f$  al centroide o prototipo  $m$ ; para todas las clases los centroides corresponden a  $v = \{v_1, v_2, \dots, v_m\}$ .

$$d_{ij} = (x_f - v_j)^T H_j (x_f - v_j) \quad (1.3)$$

En el caso de FCM,  $H_j = 1$  y  $d_{ij}$  es la distancia Euclidiana que permite hacer agrupamiento de datos en hiperesferas. Para GKM,  $H_j$  está definido de acuerdo con la ecuación (1.4), donde  $\delta_j$  es el índice volumétrico del grupo  $j$ ,  $F_j$  es la matriz de covarianza difusa del grupo  $j$ , y la agrupación de datos corresponde a hiperelipsoides que permiten una mayor posibilidad de adaptación a las formas de agrupamiento que las hiperesferas. Los algoritmos FCM y GKM requieren conocer de antemano el número de clases.

$$H_j = [\delta_j \det(F_j)]^{1/n} (F_j)^{-1} \quad (1.4)$$

Otros métodos utilizados para obtener un agrupamiento y clasificación difusa son las Redes Neuronales Artificiales y la Metodología LAMDA, los cuales guardan algunas relaciones en la conformación de sus estructuras.

Las Redes Neuronales Artificiales (RNA) se han utilizado en tareas de diagnóstico a partir del reconocimiento de patrones y de la clasificación de los datos históricos (Zemouri, 2003; Khomfoi y Tolbert, 2007).

La estructura de una RNA incluye tres capas. La primera capa de neuronas contiene los nodos de entrada y corresponde al número de descriptores o variables seleccionadas. Las capas ocultas, que asocia las entradas y salidas de la RNA. La tercera capa (o de salida) corresponde al número de clases. El resultado de una clasificación con RNA es generalmente concreta, es decir, los datos pertenece o no a una clase.

Para el aprendizaje de la RNA es necesario definir (parámetro de entrenamiento) el número de neuronas de las capas, y si es requerido el número de capas ocultas. Arquitecturas de las RNA como las Redes Neuronales con Funciones de Base Radial - Radial Basis Functional, RBF- permiten establecer automáticamente el número de neuronas (Haykin, 2008). Las RBF tienen una capa oculta de neuronas asociadas a funciones radiales (e.g. función Gaussiana) y una capa de neuronas de salida asociadas a una función lineal. En Botia et al. (2009) es propuesta una RBF como clasificador difuso en forma directa.

La técnica de clasificación LAMDA - *Learning Algorithm for Multivariate Data Analysis* - (Aguilar-Martín y López de Mantaras, 1982) es una metodología difusa de agrupamiento conceptual y clasificación que mezcla los conceptos de redes neuronales y agrupamiento difuso. Está basado en encontrar el grado de adecuación global de un individuo a una clase existente, considerando las contribuciones de cada uno de sus descriptores. Un componente numérico de  $x$  es el valor normalizado del descriptor, en caso contrario si el componente es un descriptor simbólico este valor es llamado Modalidad.

La contribución de cada variable o descriptor es llamada Grado de Adecuación Marginal - *marginal adequacy degree (MAD)*-. Cuando el descriptor es de tipo numérico, el *MAD* es calculado seleccionando una de las diferentes funciones (Aguado y Aguilar-Martin, 1999), entre estas la extensión difusa de la función binomial (1.5) y la función Gaussiana (1.6) son las más comúnmente utilizadas.

$$MAD[x_g | \rho_{jg}] = \rho_{jg}^{\tilde{x}_g'} (1 - \rho_{jg})^{(1 - \tilde{x}_g')} \quad (1.5)$$

donde  $\tilde{x}' = (x' - \min x' / \max x' - \min x')$  y  $\rho_{jg}$  corresponde al valor medio para la variable o descriptor  $g$  caracterizando la clase  $j$ .

$$MAD[x_g | m_{jg}, \sigma_{jg}] = e^{(1/2)((x_g' - m_{jg})/\sigma_{jg})^2} \quad (1.6)$$

donde,  $m$  es la media, y el parámetro  $\sigma$  mide la proximidad al prototipo.

Cuando el descriptor es cualitativo, la frecuencia observada de su modalidad de atributo es utilizada para evaluar el *MAD*. Las adecuaciones marginales son combinadas utilizando conectivos lógicos difusos como los operadores de agregación en orden a obtener el grado de adecuación global (*GAD*) de un individuo a la clase (Aguilar-Martín y López de Mantaras, 1982). Los conectivos lógicos difusos son versiones difusas de los operadores lógicos binarios, particularmente, intersección (*t-norma*) y unión (*t-conorma*). La función de agregación (Piera y Aguilar, 1991) es una interpolación lineal entre *t-norma* ( $\gamma$ ) y *t-conorma* ( $\beta$ ) como se muestra en la ec. (1.7) donde el parámetro  $\alpha$ ,  $0 \leq \alpha \leq 1$ , es llamado exigencia.

$$GAD(x'|C) = \alpha \cdot \gamma(MAD(x_1'|C), \dots, MAD(x_a'|C)) + (1 - \alpha) \cdot \beta(MAD(x_1'|C), \dots, MAD(x_a'|C)) \quad (1.7)$$

Los más comunes operadores lógicos difusos son:  $\{\gamma(a,b)=a,b ; \beta(a,b)= a+b-a,b\}$  y  $\{\gamma(a,b)=\min(a,b) ; \beta(a,b)= \max(a,b)\}$ .

Un elemento es asignado a la clase en la cual tiene el máximo *GAD*. Para evitar la asignación de un elemento no muy representativo a la clase, es decir un elemento con una pequeña pertenencia, un umbral de adecuación global mínimo es empleado, llamado clase no informativa (non-informative class, *NIC*) (Rakoto-Ravalontsalama y Aguilar-Martin, 1992). Con LAMDA es posible realizar reconocimiento pasivo, auto aprendizaje (no es requerido conocer el número de agrupamiento con antelación) o aprendizaje. Esta técnica permite el procesamiento cuantitativo, cualitativo y información de intervalos (Hedjazi et al., 2011), y no es un algoritmo iterativo.

El algoritmo LAMDA ha sido utilizado en sistemas de supervisión y diagnóstico de procesos basados en clasificadores con un excelente desempeño sirviendo como una herramienta de soporte al operador del proceso en la tarea de toma de decisiones (Waissman et al., 2005; Waissman et al., 2000; Pardo y Gauthier, 2006; Kempowsky et

al., 2006; Isaza et al., 2009; Isaza et al., 2007; Botía et al., 2012; Aguilar-Martín, 2007; Sarmiento e Isaza, 2012; Sarmiento et al., 2012; Sarmiento et al., 2013).

## 6. Predicción de estados funcionales en la supervisión y diagnóstico de procesos

Diversos algoritmos son utilizados para la estimación de estados funcionales en forma directa e indirecta. La forma indirecta permite estimar el estado funcional del proceso como consecuencia de estimar variables y/o parámetros del proceso (Weber y Gentil, 1997). La estimación directa del estado funcional es obtenida con base en el conocimiento que se puede extraer de la información histórica y actual del proceso.

Con diferentes técnicas, desde hace ya varias décadas, se ha registrado la estimación de variables y/o parámetros en sistemas donde se puede disponer de un modelo matemático aproximado. La estimación de estados (variables de estado) y la estimación de parámetros ha sido utilizada en forma efectiva en los sistemas de supervisión basados en detección de fallos (Zapata et al., 2011). Trabajos que incluyen estimación de estados han sido ampliamente reportados en diversas áreas, entre ellos, los sistemas eléctricos de potencia (Zhang et al., 2011) donde los Filtros de Kalman Extendidos -EKF (*Extended Kalman Filter*)- (Van Der Merwe y Wan; 2001) y los Cuadrados Mínimos Pesados -WLS (*Weighted Least Square*)- (Nguyen et al., 2010) son utilizados como algoritmos de estimación. En procesos químicos, la estimación de estado puede ser realizada por medio de EKF, o una amplia variedad de Observadores de estado (Botero y Álvarez, 2009). En sistemas de control de tráfico los EKF, los filtros UKF (Unscented Kalman Filter), filtros de partículas PF (Particle Filters), filtros duales o filtros conjuntos son los algoritmos utilizados (Hegyi et al., 2006). En sistemas climatológicos (estimación de lluvia y clima) han sido utilizados EKF, UKF y filtros de Kalman conjuntos (Infante et al., 2012).

En el trabajo de Prakash et al. (2011) es presentada una categorización para los métodos de estimación (basados en modelos) de estados en sistemas no lineales: los estimadores no lineales desarrollados bajo un marco de referencia determinístico, y los estimadores no lineales desarrollados bajo un marco de referencia Bayesiano. En general, los autores concluyen que los métodos de estimación que han sido desarrollados durante los últimos 40 años, son computacionalmente intensivos y requieren todavía de mucho refinamiento. La gran dificultad de estos métodos es el requerimiento de un modelo de la planta muy preciso que incluya las no linealidades de la misma, restricción que es en muchos casos imposible de cumplir por la complejidad de los sistemas no lineales y su alta dimensionalidad.

Dentro de las técnicas de estimación o predicción de estados funcionales en forma directa, aplicadas al monitoreo de procesos complejos, están los Modelos de Markov Ocultos - HMM (*Hidden Markov Models*)- (Daidone et al., 2006), y en años más recientes la utilización de técnicas de Inteligencia Artificial como Redes Neuronales Artificiales -ANN (*Artificial Neural Networks*)-, Máquinas de Soporte Vectorial -SVM (*Support Vector Machines*)- y Logica Difusa -FL(*Fuzzy Logic*)- entre otros (Roth et al., 2010). En los HMMs y las ANNs (Redes Recurrentes) la estimación es del tipo probabilística, y la dependencia de los datos históricos para definir sus estructuras es considerada una debilidad potencial. Ejemplos específicos de estimación de estados con HMMs son detallados por Roth et al. (2010), y Tobon-Mejía et al. (2011), estos trabajos fueron aplicados con éxito a nivel de dispositivos y equipos mecánicos en la estimación de estados y tiempo de vida útil.

Hasta el momento, en la literatura no se han reportado trabajos de predicción de estados funcionales basándose en los resultados de algoritmos de clasificación difusa. Sin

embargo, hay desarrollos que se pueden considerar como antecedentes; estos están relacionados con el establecimiento de lazos de conexión entre estados funcionales para construir un autómata (Klir and Yuan, 1995) para la tarea de predicción (determinar los posibles cambios durante el comportamiento del proceso).

## 7. Autómatas en la supervisión y diagnóstico de procesos

Un autómata puede ser definido como una representación gráfica que describe el comportamiento de un proceso o sistema. Esta representación incluye un número finito de estados (autómata finito) o situaciones del proceso, las transiciones entre estos estados y la forma como son activadas las transiciones. Los autómatas finitos FA (*Finite Automata*) pueden ser del tipo difuso, FFA (*Fuzzy Finite Automata*), en los cuales las transiciones y la forma como son accionadas estas transiciones son difusas.

Autómatas difusos han sido contruidos por medio de inferencia basada en reglas difusas (Chang and Chen, 2011) y a partir de los grados de membrecía difusos (Waissman et al., 2000 y 2005; Kempowsky et al., 2006; Botia et al., 2012), pero sin asociar a los lazos de conexión un peso, fuerza o valor que pueda dar indicación de la transición entre estados -que pueda ocurrir- durante el comportamiento del proceso.

Otro antecedente es el trabajo de Du y Yeung (2004) donde, en un esquema de supervisión con clasificadores, ellos propusieron una metodología para el cálculo de Probabilidades de Transición Difusas (PTD). La propuesta permite estimar la probabilidad que el sistema permanezca en el estado actual y evolucione hacia los demás estados. En esta propuesta, la formulación matemática de las Cadenas de Markov para eventos discretos es integrada con el objetivo de incluir la información temporal. Los autores (Du y Yeung, 2004) proponen utilizar en lugar de probabilidades clásicas, las Probabilidades Difusas (PD) (Zadeh, 1984), que son obtenidas mediante un clasificador desarrollado por los autores. La propuesta se limita a procesos con estados no renovables, es decir que el sistema no retorna a estados que ya se presentaron durante el funcionamiento del proceso. Un ejemplo de procesos no renovables son los procesos degradantes, como el proceso natural de desgaste de piezas mecánicas que es tratado por Du y Yeung (2006) para mostrar la efectividad de su propuesta.

En el campo de procesos complejos, como son la mayoría de procesos industriales, el sistema puede -en su normal evolución- retornar entre estados, e.g. el efecto de la acción de un controlador de nivel, presión, entre otras, puede llevar al proceso a restablecer estados. Una propuesta que permita -estando en el instante  $t$ - establecer la probabilidad del próximo estado posible en  $t+1$ , que se base en clasificadores difusos, y que permita trabajar con procesos renovables, constituye una herramienta valiosa para el operador del proceso como apoyo en la toma de decisiones.

En este documento de tesis se propone un nuevo método para estimar en línea estados funcionales en procesos complejos y obtener un autómata que permita una útil y rápida visualización de los resultados de predicción. La propuesta integra las ventajas de los clasificadores difusos, la tarea de estimación y la característica de ser aplicable a procesos renovables. La parte esencial de la metodología es la integración de la información difusa -obtenida con el agrupamiento- a la formulación matemática de las Cadenas de Markov para hacer posible la tarea de estimación.



## 8. Conclusión

Se describieron generalidades de la supervisión y diagnóstico en procesos complejos. Se presentaron tópicos propios de la supervisión de procesos que justifican la necesidad y relevancia de nuevas propuestas para mejorar o proponer metodologías para realizar tareas de vigilancia, monitoreo y diagnóstico con eficacia y eficiencia.

Partiendo de la definición de sistemas complejos se destacaron los problemas asociados con las tareas de supervisión requeridas, entre ellas la dificultad para obtener modelos de los procesos complejos, que asociado a la ventaja actual de poder disponer de registros históricos justifica la utilización de métodos basados en datos. Los métodos basados en datos permiten obtener clases representativas que pueden ser asociadas a estados funcionales o situaciones por medio de las cuales se reconoce el estado actual del proceso, y como consecuencia poder tomar las acciones que se requieran.

Las herramientas que integran el aporte de la inteligencia artificial asociada a los esquemas de supervisión basados en clasificadores, han permitido dar respuesta a los problemas de análisis multivariable, reducción de dimensionalidad, la interacción hombre-máquina, y la naturaleza difusa e incertidumbre asociada a las variables registradas en los procesos. Estos elementos entre otros, han dado relevancia a los métodos de Clasificación Difusa.

Estos métodos de clasificación ayudan a encontrar clases que se asocian a estados funcionales del proceso y que pueden ser posteriormente reconocidos por el operario del proceso. Con esta información se puede establecer conexiones entre estados funcionales, que se representan por el grafo de conexiones de un Autómata Difuso. Esta representación permite observar los cambios en el comportamiento del proceso y predecir fallas que pueden suceder.

Esta predicción de estados funcionales es la tarea valiosa, por lo cual son relacionadas diferentes propuestas resaltando sus características (bondades y desventajas) y se justifica la realización de propuestas de estimación de estados funcionales.